

이항 분류 모델링을 적용한 실시간 낙상 예측 데이터 분석

방찬우¹, 김동률¹, 김봉현^{2*}

¹서원대학교 컴퓨터공학과 학생, ²서원대학교 컴퓨터공학과 교수

Real-time Fall Prediction Data Analysis using Binary Classification Modeling

Chan-Woo Bang¹, Dong-Ryul Kim¹, Bong-Hyun Kim^{2*}

¹Student, Department of Computer Engineering, Seowon University

²Professor, Department of Computer Engineering, Seowon University

요약 낙상사고는 많은 재활 비용을 필요로 하고, 다른 안전사고에 비해 대부분 예방이 가능하다는 점에서 올바른 정보제공을 통한 사전 예방이 더욱 중요하다. 특히, 고령자의 경우 연령증가에 따른 신체의 노화 및 질병은 안전사고의 증가로 이어질 수 있고 상해의 정도도 심각한 실정이다. 따라서, 본 논문에서는 환자에 부착된 통합 센서 모듈에서 실시간으로 수집되는 데이터를 기반으로 낙상 사고에 대한 예측 데이터 모델링을 통해 실시간으로 낙상에 대한 모니터링이 가능한 데이터 분석을 연구하였다. 이를 위해 온도 센서, 심박 센서 및 모션 센서에서 실시간으로 데이터를 수집하고 이항 분류 모델링을 적용한 낙상 예측 데이터 분석을 수행하였다.

주제어 : 낙상 예측, 이항 분류, 아담 함수, 온도 센서, 심박 센서, 모션 센서

Abstract Fall accidents require a lot of rehabilitation costs. Since most of the accidents can be prevented compared to other safety accidents, it is more important to prevent them in advance by providing correct information. In particular, in the case of the elderly, body aging and disease due to an increase in age can lead to an increase in safety accidents, and the degree of injury is serious. Therefore, in this paper, we designed predictive data modeling for a fall accident based on the data collected in real time from the integrated sensor module attached to the patient. In addition, data analysis that can monitor falls in real time was studied. To this end, data was collected in real time from temperature sensors, heart rate sensors, and motion sensors, and fall prediction data analysis was performed by applying binomial classification modeling.

Key Words : Fall prediction, Binary classification, Adam function, Temperature sensor, Heart rate sensor, Motion sensor

1. 서론

2018년 환자안전 사고를 분석한 결과 사고의 절반은 침대에서 떨어지거나 넘어지는 등 낙상인 것으로

나타났다. 2018년 환자안전 사고 자율보고 건수는 이 전해보다 2.4배 증가한 9250건이었다[1].

사고 종류별로 분류해 보면 낙상(4224건, 45.7%)이 가장 많았고, 다음으로 투약(2602건, 28.1%), 검사(533

* 본 논문은 2020년도 정부(교육부)의 재원으로 한국연구재단의 지원을 받아 수행된 기초연구사업임(NRF-2018R1D1A1B07049318)

*Corresponding Author : Bong-Hyun Kim (bhkim@seowon.ac.kr)

Received November 13, 2020

Revised January 12, 2021

Accepted February 06, 2021

Published February 28, 2021

건, 5.8%), 진료재료 오염·불량(433건, 4.7%), 감염 관련(161건, 1.7%) 순이었다. 발생 장소는 입원실(4310건, 46.6%)과 검사실(641건, 6.9%)이 절반 이상을 차지했고, 응급실(297건, 3.2%), 중환자실(275건, 3.0%) 등이 뒤를 이었다. 사고가 환자에게 미친 영향을 살펴보면, 위해 없음(4485건, 48.5%), 치료 뒤 후유증 없이 회복(2784건, 30.1%), 일시적인 손상 또는 부작용(1295건, 14%) 등 위해 정도가 낮은 사고들이 주로 보고됐다. 하지만 장기적인 손상 또는 부작용(562건, 6.1%), 영구적인 손상 또는 부작용(22건 0.2%), 사망(95건, 1%) 등 위해 정도가 높은 사고도 전체 보고 건수의 7.3%를 차지했다[2-4].

2019년도 의료기관평가인증원에서 발간한 환자안전 통계연보에 따르면 19년 환자안전사고 자율보고 건수는 최근 4년간 꾸준히 증가해 '18년에 비해 약 1.3배 증가한 1만1953건이 보고되는 등 지속적인 증가세를 보이며 활성화되고 있다[4-5].

또한, 사고가 환자에게 미친 영향별로 살펴보면 위해 없음(6034건, 50.5%), 치료 후 후유증 없이 회복(3350건, 28.0%), 일시적인 손상 또는 부작용(1709건, 14.3%) 등 위해 정도가 낮은 사고들이 주로 보고됐으며, 장기적인 손상 또는 부작용(726건, 6.1%), 영구적인 손상 또는 부작용(18건 0.2%), 사망(98건, 0.8%) 등과 같이 위해 정도가 높은 사고도 전체 보고건수의 7.1%를 차지했다[6].

사고의 종류는 2018년과 동일하게 낙상(5293건, 44.3%), 투약(3798건, 31.8%), 검사(715건, 6.0%), 진료재료 오염·불량(217건, 1.8%), 감염 관련(174건, 1.5%) 등의 순으로 보고됐으며, 이 가운데 투약의 사고보고는 전년대비 약 46%가량 증가했다. 즉, 환자 안전 사고 유형에서 낙상으로 인한 사고가 44.3%로 최고치에 달하고 있는 실정이다. 그만큼 추락으로 인한 낙상사고는 고령자에게 심각한 상해를 초래할 수 있어 각별한 주의가 요구되고 있다[7-8].

미국질병통제예방센터(CDC, Centers for Disease Control and Prevention)에 따르면 미국의 65세 이상 고령자의 손상 원인 1위는 낙상이었으며, 2014년에는 약 2만7천 명이 낙상으로 사망한 것으로 나타났다. 낙상으로 응급실 처치를 받은 사람은 280만 명이고, 이들

중 80만 명은 입원치료를 받아야 했던 것으로 확인되고 있다[6-8].

추락·낙상사고는 많은 재활 비용을 필요로 하고, 다른 안전사고에 비해 대부분 예방이 가능하다는 점에서 올바른 정보제공을 통한 사전 예방이 더욱 중요하다. 고령자의 경우 연령증가에 따른 신체의 노화 및 질병은 안전사고의 증가로 이어질 수 있고 상해의 정도도 심각한 실정이며, 아동의 경우 새로운 제품과 시설물이 출현하면서 위해·위험요소가 증가하고 이에 따라 안전취약계층인 어린이는 지속적으로 안전사고 위험에 노출되고 있는 실정이다. 이에, 신체적 대응능력이 떨어지는 고령자와 위험한 상황에 대한 인식능력이 부족한 아동을 위한 지속적인 관찰과 안전사고 발생 시 신속한 대응이 이루어 질 수 있는 수단이 필요하다.

따라서, 본 논문에서는 환자에 부착된 통합 센서 모듈에서 실시간으로 수집되는 데이터를 기반으로 낙상 사고에 대한 예측 데이터 모델링을 통해 실시간으로 낙상에 대한 모니터링이 가능한 데이터 분석을 연구하였다. 이를 위해 온도 센서, 심박 센서 및 모션 센서에서 실시간으로 데이터를 수집하고 이항 분류 모델링을 적용한 낙상 예측 데이터 분석을 수행하였다.

II. 딥러닝 모델링

2.1 다중 분류 모델

딥러닝 분류 모델링에서 다수 개의 답 중 하나를 고르는 분류 문제를 다중 분류라 한다. 딥러닝 네트워크에서 다중 분류 문제를 위한 활성화 함수는 주로 소프트맥스 함수를 이용한다. 소프트맥스 함수는 분류해야 하는 정답지(클래스)의 총 개수를 k 라고 할 때, k 차원의 벡터를 입력받아 각 클래스에 대한 확률을 추정하는 방식이다.

Softmax는 각각 Label별로 확률을 출력하는 활성화 함수이며, 모든 출력 값을 합치면 1이 된다. Softmax는 큰 값을 강조하고, 작은 값을 약화시키는 효과를 가져온다. k 차원의 벡터에서 i 번째 원소를 z_i , i 번째 클래스가 정답일 확률을 p_i 로 나타낸다고 하였을 때, 소프트맥스 함수는 p_i 를 아래와 같이 정의한다[9].

$$P_i = \frac{e^{z_i}}{\sum_{j=1}^k e^{z_j}} \quad (i = 1, 2, 3, \dots, k) \quad (1)$$

만약, 풀어야하는 문제가 3개인 경우, $k=3$ 이므로 3차원 벡터 $z=[z_1 \ z_2 \ z_3]$ 의 입력을 받으며, 소프트맥스 함수는 아래와 같은 출력을 리턴한다.

$$Sm(z) = \left[\frac{e^{z_1}}{\sum_{j=1}^3 e^{z_j}}, \frac{e^{z_2}}{\sum_{j=1}^3 e^{z_j}}, \frac{e^{z_3}}{\sum_{j=1}^3 e^{z_j}} \right] = [p_1, p_2, p_3] = \hat{y} \quad (2)$$

이때, \hat{y} 는 예측값이 되며, p_1, p_2, p_3 각각은 1번 클래스가 정답일 확률, 2번 클래스가 정답일 확률, 3번 클래스가 정답일 확률을 나타내며 각각 0과 1사이의 값으로 총 합은 1이 된다[10].

즉, 분류하고자 하는 클래스가 k 개일 때, k 차원의 벡터를 입력받아서 모든 벡터 원소의 값을 0과 1사이의 값으로 값을 변경하여 다시 k 차원의 벡터를 리턴한다.

다중 분류에서 사용하는 대표적인 손실 함수가 categorical_crossentropy이다. 엔트로피(entropy)는 데이터를 숫자로 정량화하는 단위를 의미한다. 엔트로피는 확률의 역수에 로그를 취한 값이며, 확률이 높을수록 데이터의 중요도가 낮다고 판단하기 때문에 역수를 취한다. 크로스 엔트로피(crossentropy)는 각 엔트로피에 확률을 곱해준 기댓값과 유사하다. 확률 대신 네트워크가 예측한 확률값을 곱하며, 네트워크가 예측한 값을 $q(x)$ 라고 한다.

이항은 두 개부터, 다항은 세 개 이상의 범주로 이루어져 있으며, 범주형 크로스 엔트로피(categorical cross entropy, CCE)는 모든 범주에 대한 크로스 엔트로피의 평균을 내는 것을 의미한다[11].

$$CCE = \frac{1}{n} \sum_{i=1}^n p_i(x) \log \frac{1}{q_i(x)} \quad (3)$$

2.2 이항 분류 모델

다중 분류와는 다르게 둘 중에 하나를 고르는 분류

문제를 이항 분류라 한다. 즉, 2개의 Label을 갖는 데이터가 들어왔을 때, 0 또는 1로 분류를 하는 것을 의미한다.

딥러닝에서 이항 분류 모델은 활성화 함수로 주로 Sigmoid 함수를 사용한다. Sigmoid 함수가 0 또는 1로 출력을 하기 때문이다. Sigmoid 대신 Softmax를 사용하는 것도 가능하다. 이러한, 이진 분류 문제의 해결에 사용되는 대표적인 알고리즘이 로지스틱 회귀이다.

로지스틱 회귀의 가설은 선형 회귀 때의 $H(x) = Wx + b$ 가 아니다. S자 모양의 그래프를 만들 수 있는 어떤 특정 함수 f 를 추가적으로 사용하여 $H(x) = f(Wx + b)$ 의 가설을 사용한다. 어떤 함수 f 는 이미 널리 알려져 있으며, 이를 시그모이드 함수라 한다. 즉, 로지스틱 회귀의 가설이자 이진 분류 문제를 풀기 위한 함수 f 는 Sigmoid function이다[12].

$$\begin{aligned} H(x) &= \text{sigmoid}(Wx + b) \\ &= \frac{1}{1 + e^{-(Wx + b)}} \\ &= \sigma(Wx + b) \end{aligned} \quad (4)$$

시그모이드 함수는 입력값이 한없이 커지면 1에 수렴하고, 입력값이 한없이 작아지면 0에 수렴한다. 시그모이드 함수의 출력은 0에서 1사이이며, 위의 특성을 이용하여 분류 작업에 사용된다. 임계값 $x(0 \leq x \leq 1)$ 를 넘으면 1, 넘지 못하면 0으로 분류한다[13].

이러한, 이진 분류에서 대표적으로 사용되는 손실 함수는 Cross Entropy Error(CEE)이다.

$$CEE = - \sum_{i=1}^n t_i \log y_i \quad (5)$$

t 는 정답 값이고, y 는 추론 값이다. 정답의 개수와 추론의 개수는 일치하며, 이 개수가 2개이면 이진분류이고 2개보다 많으면 다중분류이다. y 값은 신경망 여러 개를 거쳐 산출된 값이 최종 마지막의 어떤 특별한 활성화함수의 입력값이 되어 산출된 결과값이다. 따라서, 이진분류로 가장 많이 사용되는 활성화함수는 Sigmoid이고 다중분류로 가장 많이 사용되는 것이 Softmax이다.

III. 센싱 데이터 관리

본 논문에서는 실시간 낙상 사고에 대한 데이터 분석 및 예측 모델 설계를 위해 온도 센서를 이용한 체온 측정, 심박 센서를 이용한 심장 박동수 측정 및 모션 센서를 이용한 위치 변화 측정 등을 수행하고 실시간으로 데이터를 수집, 관리하였다.

먼저, 체온 측정을 위한 비접촉식 온도 센서는 적외선 (IR) 방출을 통해 원격 물체의 온도를 감지하는 웨이퍼 칩 스케일 패키지 (WCSP)의 통합 디지털 써모파일 온도 센서를 사용하였다. 원격 비접촉 온도 감지가 필요한 열 관리 및 열 보호 애플리케이션에 적합한 방식의 TMP007은 2 선식 및 SMBus 인터페이스와 호환되며, -40°C 에서 125°C 까지의 온도 범위에서 지정된다. TMP007에는 구성 및 교정 정보, 온도 제한, 로컬 온도, TDIE, 측정 결과 및 열전 전압 측정 결과를 저장하기 위한 레지스터가 포함되어 있다[14-15]. 아래 Fig. 1은 TMP007 온도 센서에 대한 기능도를 나타낸 것이다.




Fig. 1. TMP007 functional block diagram

다음으로, DFRobot 심박 센서를 사용하여 심장 박동수를 측정하였다. DFRobot 심박 센서는 PPG (Photo Plethysmo Graphy) 기술을 기반으로 개발된 맥박 센서이다. 이론에 따르면 심장 주기의 박동 성분을 감지하는 것은 상대적으로 쉽게 설명되어 있다. DFRobot 센서에는 벨트에 부착하는 데 사용할 수 있는 두 개의 구멍이 있다. 이를 통해, 손가락, 손목, 컷볼 또는 피부와 접촉하는 기타 부위를 감쌀 수 있다. 또한, DFRobot 심박 센서에는 아날로그 펄스 모드와 디지털 구형파 모드의 두 가지 신호 출력 모드가 있으며, 다이얼 스위치를 사용하여 출력 모드를 변경할 수 있다[15-16]. Fig. 2는 DFRobot 센서와 보드 연결도를 나타낸 것이다.




Fig. 2. DFRobot connection diagram

마지막으로, MPU-60X0 모션 처리 장치는 핸드셋 및 태블릿 애플리케이션, 게임 컨트롤러, 모션 포인터 원격 제어 및 기타 소비자 장치용으로 통합 9축 센서 융합을 갖춘 세계 최초의 모션 처리 솔루션이다. 빠른 동작과 느린 동작 모두의 정밀한 추적을 위해 부품은 $\pm 250, \pm 500, \pm 1000$ 및 $\pm 2000^{\circ} / \text{sec}$ (dps)의 사용자 프로그래밍 가능한 자이로 스코프 풀 스케일 범위와 풀 스케일 사용자 프로그래밍 가능 가속도계를 특징으로 한다. 따라서 MPU-60X0은 시스템 프로세서에 대한 처리 요구 사항이 감소된 휴대용 애플리케이션에서 저전력 Motion Processing을 가능하게 한다[16]. Fig. 3은 MPU-60X0의 블록도를 나타낸 것이다.




Fig. 3. MPU-60X0 block diagram

최종적으로, 센싱 데이터 관리를 위한 시스템 구현에서는 센서를 통해 수집되는 데이터는 1초 단위로 저장하고 관리하도록 설계하였다. 즉, 사용자의 센서 디바이스를 통해 데이터가 측정되면 무선 라우터를 이용하여 데이터를 전송하도록 하였다. 또한, 서버 시스템에서는 센서 데이터 저장, 데이터 분석 및 이상 데이터에 대한 알람 전송 등의 기능을 수행하도록 구성하였다. Fig. 4는 데이터 수집, 저장, 관리 및 분석 등에 대한 프로세스 진행 구성도를 나타낸 것이다.

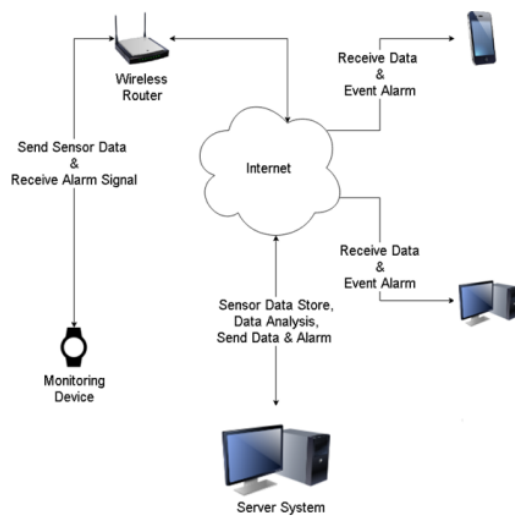


Fig. 4. Data process diagram

IV. 결과 분석

본 논문에서는 환자에 부착된 통합 센서 모듈에서 실시간으로 수집되는 데이터를 기반으로 낙상 사고에 대한 예측 데이터 모델링을 통해 실시간으로 낙상에 대한 모니터링이 가능한 데이터 분석을 연구하였다. 이를 위해 온도 센서, 심박 센서 및 모션 센서에서 실시간으로 데이터를 수집하고 이항 분류 모델링을 적용한 낙상 예측 데이터 분석을 수행하였다.

낙상 예측 데이터 분석 프로세스는 사용자의 센서 디바이스를 통해 데이터가 측정되면 무선 라우터를 이용하여 데이터를 전송하도록 하였다. 또한, 서버 시스템에서는 센서 데이터 저장, 데이터 분석 및 이상 데이터에

대한 알람 전송 등의 기능을 수행하도록 구성하였다. 마지막으로, 센서 디바이스를 통해 입력되는 데이터에 대한 수집 및 저장은 서버 시스템에서 실시간으로 모니터링하고 관리할 수 있도록 하였다. Fig. 5는 서버 시스템에서 모니터링되는 수집 데이터를 나타낸 것이다.

```

Received Sensor Data : 1,23.6,46.5,2020.8,4,16,0.27
Received Sensor Data : 1,23.6,38.8,2020.8,4,16,0.28
Received Sensor Data : 1,23.6,53.7,2020.8,4,16,0.29
Received Sensor Data : 1,25.5,43.7,2020.8,4,16,0.30
Received Sensor Data : 1,25.7,50.4,2020.8,4,16,0.31
Received Sensor Data : 1,25.7,49.4,2020.8,4,16,0.32
Received Sensor Data : 1,25.7,48.4,2020.8,4,16,0.33
Received Sensor Data : 1,27.0,48.4,2020.8,4,16,0.34
Received Sensor Data : 1,27.4,48.4,2020.8,4,16,0.35
Received Sensor Data : 1,27.4,48.4,2020.8,4,16,0.36
Received Sensor Data : 1,27.4,57.6,2020.8,4,16,0.37
Received Sensor Data : 1,28.1,43.6,2020.8,4,16,0.38
Received Sensor Data : 1,28.3,46.6,2020.8,4,16,0.39
Received Sensor Data : 1,28.3,39.5,2020.8,4,16,0.40
Received Sensor Data : 1,28.3,44.5,2020.8,4,16,0.41
Received Sensor Data : 1,29.3,53.24,2020.8,4,16,0.42
Received Sensor Data : 1,29.6,41.25,2020.8,4,16,0.43
Received Sensor Data : 1,29.6,38.8,2020.8,4,16,0.44
Received Sensor Data : 1,29.6,59.29,2020.8,4,16,0.45
Received Sensor Data : 1,31.0,45.24,2020.8,4,16,0.46
Received Sensor Data : 1,31.3,42.18,2020.8,4,16,0.47
Received Sensor Data : 1,31.3,32.5,2020.8,4,16,0.48
Received Sensor Data : 1,31.3,44.8,2020.8,4,16,0.49
  
```

Fig. 5. Server system monitoring screen

서버 시스템에서 수집되는 데이터는 관리자 시스템으로 실시간 전송되며, 관리자 모니터링 모드에서는 전송 데이터를 그래프로 시각화하여 표현하도록 하였다. Fig. 6은 관리자 시스템에서의 모니터링 화면을 나타낸 것이다.




Fig. 6. Manager system monitoring screen

마지막으로, 센서를 통해 측정된 데이터를 기반으로 낙상 사고에 대한 유무를 판단하기 위해 이항 분류 모델을 적용한 딥러닝 분석을 수행하였다. Fig. 7은 수집된 데이터를 딥러닝 분석에 적용하기 위해 엑셀로 변환한 것을 나타낸 것이다.

No.	Timestamp	Device ID	Temperature	Heart Rate	Motion
163	2020-10-11 18:03:31	1	34.9	30	5
164	2020-10-11 18:03:32	1	36.4	43	4
165	2020-10-11 18:03:33	1	36.4	49	4
166	2020-10-11 18:03:34	1	36.4	32	4
167	2020-10-11 18:03:35	1	36.4	38	5
168	2020-10-11 18:03:36	1	37.7	43	4
169	2020-10-11 18:03:37	1	37.7	39	4
170	2020-10-11 18:03:38	1	37.7	39	5
171	2020-10-11 18:03:39	1	37.7	38	5
172	2020-10-11 18:03:40	1	38.2	39	5
173	2020-10-11 18:03:41	1	38.2	39	5
174	2020-10-11 18:03:42	1	38.2	39	4
175	2020-10-11 18:03:43	1	38.2	40	5
176	2020-10-11 18:03:44	1	38.4	39	9
177	2020-10-11 18:03:45	1	38.4	42	29
178	2020-10-11 18:03:46	1	38.4	40	30
179	2020-10-11 18:03:47	1	38.4	39	32
180	2020-10-11 18:03:48	1	37.4	31	5
181	2020-10-11 18:03:49	1	37.3	35	4
182	2020-10-11 18:03:51	1	37.3	35	4
183	2020-10-11 18:03:51	1	37.3	35	5
184	2020-10-11 18:03:52	1	35.1	35	5
185	2020-10-11 18:03:53	1	34.9	35	4
186	2020-10-11 18:03:54	1	34.9	35	4

Fig. 7. Excel conversion data

최종적으로, 논문에서 낙상 사고 예측을 위해 사용한 입력 데이터는 체온, 심박, 모션 센서에서 측정된 3개의 속성과 1개의 클래스로 구성되었으며, 총 1,500개의 항목으로 이루어져 있다. 3개의 속성 정보는 체온, 심장 박동수, 움직임 등으로 사용자 상태를 실시간으로 측정해서 저장한 것이다. 마지막 4번째 정보는 낙상에 대한 정보로 1 또는 0으로 표현하였다. 즉, 1은 낙상 사고가 발생한 것이며, 0은 그렇지 않은 경우에 해당한다.

낙상 사고 예측을 위해 입력층 1개와 은닉층 2개, 낙상 사고를 예측해주는 출력층 1개의 모델을 구축했다. 데이터는 테스트셋과 학습셋을 각각 3:7의 비율로 나눴다. 출력층은 낙상 사고인지(1) 아닌지(0)를 하나의 값으로 출력하기 때문에 활성화 함수로 시그모이드 함수를 사용하였다. 출력층을 제외한 층에는 현재 가장 많이 사용되고 있는 렐루 함수를 사용했다. 많은 노드를 사용하였기 때문에 dropout을 사용하여 임의로 20%의 노드를 꺼주어 과적합을 방지하였다. Fig. 8은 model.add() 함수를 이용해 딥러닝 모델에서 은닉층을 추가한 것을 나타낸 것이다.

```
model = Sequential()
model.add(Dense(12, input_dim=8, activation='relu'))
model.add(Dense(8, activation='relu'))
model.add(Dense(1, activation='sigmoid'))
```

Fig. 8. Model setting

낙상 사고 예측을 위한 분석은 낙상인지 아닌지 둘 중 하나를 결정하는 이항 분류 문제이므로 오차 함수는 binary_crossentropy를 사용하였고, 최적화 함수로 adam을 사용하였다. 그리고, 전체 샘플이 100번 반복해서 입력될 때까지 실험을 반복하였으며, 한 번에 입력되는 입력 값을 10개로 하여 분석을 수행하였다. 최종, 테스트셋으로 테스트를 수행한 결과, 정확도는 0.8612로 도출되었다.

V. 결론

환자안전사고 보고 건수가 3년간 3배 이상 급증한 것으로 나타났다. 이에 유사사고 재발방지를 위한 국가 차원의 예방대책 마련이 필요하다는 의견이 제기되고 있다.

지난 3년간 환자안전사고를 사고유형별로 살펴보면, 총 3만4,352건 중 낙상사고가 46.1%인 1만5,840건으로 가장 많았고, 약물오류가 30.7%인 1만561건, 진료재료 오염 및 불량 2.4%인 832건, 감염이 1.2%인 418건, 처치 및 시술이 1.1%인 385건, 수술이 1.1%인 377건, 의료장비가 0.9%인 313건, 환자 자살 및 자해가 0.9%인 300명 순으로 집계되고 있다. 그만큼 낙상사고는 환자안전사고에서 가장 큰 비중을 차지하고 있으며, 이로 인한 사망사고 발생률까지 증가하고 있는 실정이다.

따라서, 본 논문에서는 환자에 부착된 통합 센서 모듈에서 실시간으로 수집되는 데이터를 기반으로 낙상 사고에 대한 예측 데이터 모델링을 통해 실시간으로 낙상에 대한 모니터링이 가능한 데이터 분석을 연구하였다. 이를 위해 온도 센서, 심박 센서 및 모션 센서에서 실시간으로 데이터를 수집하고 이항 분류 모델링을 적용한 낙상 예측 데이터 분석을 수행하였다.

논문에서 낙상 사고 예측을 위해 사용한 입력 데이터는 체온, 심박, 모션 센서에서 측정된 3개의 속성과 1개

의 클래스로 구성되었으며, 총 1,500개의 항목으로 이루어져 있다. 3개의 속성 정보는 체온, 심장 박동수, 움직임 등으로 사용자 상태를 실시간으로 측정해서 저장한 것이고, 마지막 4번째 정보는 낙상 유무에 대한 정보를 저장하였다. 최종적으로, 이항 분류 모델을 적용하여 분석을 수행하였으며, 오차 함수는 binary_crossentropy를 사용하였고, 최적화 함수로 adam을 사용하였다. 최종, 테스트셋으로 테스트를 수행한 결과, 정확도는 0.8612로 도출되었다.

REFERENCES

- [1] M. Y. Kim. (2019). Study on Safety·Security Design Guideline for Improving Home Safety of the Elderly. *Design Research*, 4(2), 9-19.
- [2] E. H. Choi, M. S. Ko, C. S. Yoo & M. K. Kim. (2017). Characteristics of fall events and fall risk factors among inpatients in general hospital in Korea. *Journal of Korean Clinical Nursing Research*, 23(3), 350-360. DOI : 10.22650/JKCNr.2017.23.3.350
- [3] J. H. Kim, S. J. Shin & E. Lee. (2018). Changes in clinical practice environment of nursing students due to comprehensive nursing care services. *Journal of Korean Public Health Nursing*, 32(2), 221-234. DOI : 10.5932/JKPHN.2018.32.2.221
- [4] Y. O. Kang & R. Song. (2018). Effects of fall prevention education program on attitudes, prevention behaviors and satisfaction among elderly in-patients. *Korean Journal of Adult Nursing*, 30(1), 49-59. DOI : 10.7475/kjan.2018.30.1.49
- [5] H. O. Lee, B. H. Lee & C. H. Lee. (2017). Effects of strength exercise on patient fall prevention program: Focusing on the fall high risk group elderly patients. *Journal of Health Informatics and Statistics*, 42(2), 338-345. DOI : 10.21032/jhis.2017.42.4.338
- [6] S. Y. Park & H. O. Ju. (2017). The Effect of Pediatric Inpatient Fall Prevention Education on Caregivers' Fall-related Knowledge and Preventive Behaviors. *The Journal of Korean Academic Society of Nursing Education*, 23(4), 398-408. DOI : 10.5977/jkasne.2017.23.4.398
- [7] R. Bodil, A. T. Bente, L. Stian & G. F. Per. (2019). Effects of a fall prevention program in elderly: A pragmatic observational study in two orthopedic departments. *Clinical Intervention in Aging*, 14, 145-154. DOI : 10.2147/CIA.S191832
- [8] S. Hwang & S. Shin. (2013). Predictors of fall prevention behaviors in elderly patients. *Korean Journal of Health Promotion*, 13(2), 76-85.
- [9] S. J. Pan. (2009). A Survey on Transfer Learning. *IEEE Transactions of Knowledge and Data Engineer*, 22(10), 1345-1359.
- [10] O. Russakovsky. (2015). ImageNet Large Scale Visual Recognition Challenge. *International Journal of Computer Vision*, 115(3), 211-252.
- [11] J. Lee. (2015). Deep Learning Method for Effective Learning of Imbalanced Data. *Proceedings of KIIS Spring Conference*, 25(1), 113-114.
- [12] A. Krizhevsky. (2012). Imagenet classification with deep convolutional neural networks. *Advances in Neural Information Processing Systems*, 1097-1105.
- [13] H. D. Choi. (2017). CNN Output Optimization for More Balanced Classification. *International Journal of Fuzzy Logic and Intelligent systems*, 17(2), 98-106.
- [14] K. K. Sung. (2017). A Study on the IoT Technology Trend and Utilization Plan. *Journal of Next-generation Convergence Technology Association*, 1(3), 121-127.

- [15] S. J. Hong, S. H. Lee & D. W. Jeong. (2020). Design and Implementation of a Fall Recognition System Based on 3-Axis Acceleration Data and Altitude Data for Improvement of Fall Recognition Accuracy and Convenience. *Journal of Korean Institute of Information Technology*, 18(1), 115-125.
- [16] J. H. Bang & B. Basnet. (2018). Application of IoT and Moving Average Algorithm in E-Agriculture. *Journal of Next-generation Convergence Technology Association*, 2(1), 1-5.

저 자 약 력

방찬우(Bang, Chan Woo)

[회원]



· 2016년 3월~현재 : 서원대학교
컴퓨터공학과 재학
E-Mail : bcw0219@naver.com

<관심분야>

데이터사이언스, 딥러닝, IoT 서비스

김동률(Kim, Dong Ryul)

[회원]



· 2016년 3월~현재 : 서원대학교
컴퓨터공학과 재학
E-Mail : lancetol672@naver.com

<관심분야>

데이터사이언스, 딥러닝, IoT 서비스

김봉현(Kim, Bong Hyun)

[회원]



· 2002년 2월 : 한밭대학교 전자계
산학과(공학석사)
· 2009년 2월 : 한밭대학교 컴퓨터
공학과(공학박사)
· 2012년~2015년 : 경남대학교
컴퓨터공학과 교수
· 2020년 3월~현재 : 서원대학교
IT학부 컴퓨터공학과 교수
E-Mail : bhkim@seowon.ac.kr

<관심분야>

데이터사이언스, IoT, 딥러닝, 헬스케어 서비스